

MCBPnet: 一种高效的轻量级青杏识别模型

师 翊^{1,2,3}, 王应宽^{1,3*}, 王 菲², 卿顺浩², 赵 龙⁴, 宇文星璨²

(1. 农业农村部规划设计研究院, 北京 100125; 2. 河南科技大学农业装备工程学院, 洛阳 471003;
3. 中国农业工程学会, 北京 100125; 4. 河南科技大学园艺与植物保护学院, 洛阳 471003)

摘 要: 为解决青杏识别易受田间复杂环境、设备计算资源等限制的问题, 该研究提出一种 MCBPnet 轻量化青杏识别模型。该研究使用 MobileNetV3 轻量化网络结构代替 YOLOv8 的主干特征提取网络, 降低了模型的复杂程度; 在 MobileNetV3 网络中融入 CBAM (convolutional block attention module), 在颈部网络引入了 BiFPN (bi-directional feature pyramid network) 结构, 提高模型对青杏图像的特征提取和融合的能力; 检测头部分采用了 PConv (partial convolution) 结构, 以提高模型的鲁棒性和检测精度。将 MCBPnet 模型应用于青杏检测试验, 结果表明, MCBPnet 模型的检测速度为 109.890 帧/s, 与 YOLOv8n 模型相比提高了 70.33%, 模型运算量为 6.1 G, 为 YOLOv8n 模型的 75.31%, 并且精确度 (precision, P) 和平均精度值 (mean average precision, mAP₅₀) 达到了 0.988 和 0.994, 模型具有较高的检测精度, 同时实现了模型的轻量化。MCBPnet 模型实现了对青杏果实的高效、精确的实时检测, 为青杏的自动化识别和采摘提供了技术支持。

关键词: 识别; 目标检测; 计算机视觉; 轻量化模型; 青杏; 自动化农业

doi: 10.11975/j.issn.1002-6819.202410079

中图分类号: TP391; S24

文献标志码: A

文章编号: 1002-6819(2025)-05-0156-09

师翊, 王应宽, 王菲, 等. MCBPnet: 一种高效的轻量级青杏识别模型[J]. 农业工程学报, 2025, 41(5): 156-164. doi: 10.11975/j.issn.1002-6819.202410079 <http://www.tcsae.org>

SHI Yi, WANG Yingkuan, WANG Fei, et al. MCBPnet as an efficient and lightweight recognition model for green apricot fruits[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2025, 41(5): 156-164. (in Chinese with English abstract) doi: 10.11975/j.issn.1002-6819.202410079 <http://www.tcsae.org>

0 引 言

在现代农业生产中, 果实识别技术对于提高作物管理效率、优化资源分配以及提升果实品质具有重要意义^[1-2]。青杏作为一种重要的经济作物, 不仅在农业经济中占据着举足轻重的地位, 而且在食品加工领域也发挥着不可或缺的作用, 在促进地区经济发展、增加农民收入方面具有重要意义^[3-4]。传统的青杏识别方法主要依赖于人工检查, 这种方法不仅效率较低, 而且容易受到主观因素的影响, 难以满足大规模、高效率的生产需求^[5-6]。由于青杏的外观特征与周围环境高度相似, 尤其是在自然光照、多变气候、植物遮挡以及果实相互重叠等多变条件下, 传统的图像分析方法和基于机器学习的识别技术面临着挑战, 难以实现精确的青杏定位和识别。

因此, 研发一种能够适应复杂环境并提高识别准确性的青杏识别方法, 对于提升农业生产的自动化水平和提高经济效益具有重要意义。

近年来, 深度学习技术, 特别是卷积神经网络 (convolutional neural networks, CNN), 在目标检测领域取得了突破性进展^[7-9]。在目标检测算法的研究中, 两阶段检测算法, 如 R-CNN 系列和 Mask R-CNN, 通过选择性搜索提取候选区域和生成目标掩码分支, 提升了识别的准确性^[10]。但因其模型复杂、检测速度慢, 难以满足自动化果实识别检测的需求^[11-12]。相较于两阶段检测算法, 单阶段检测算法因其快速的检测速度和较高的实时性, 更适用于自动化识别果实任务, 这类算法可直接预测目标的类别和位置信息, 无需复杂的区域选择过程^[13-14]。EfficientDet^[15-16]、RetinaNet^[17-19]、SSD 和 YOLO 等模型是单阶段目标检测算法中应用较为广泛的方法。其中, YOLO 系列算法通过将目标检测问题转化为回归问题, 直接预测目标的类别和位置信息, 确保了快速的检测速度和高效的实时性能, 在目标检测中占据重要地位^[20-22]。在水果自动化检测领域, 张震等^[23]提出了一种基于改进 YOLOv7 的轻量化苹果检测模型, 能够实时准确地识别复杂果园环境中的苹果。刘莫尘等^[24]针对大棚草莓开发了一种改进的 YOLOv8-Pose 模型, 通过引入轻量化模块, 提高了模型对红熟期草莓及其果柄关键点的检测能力。SUN 等^[25]提出了一种基于改进 YOLOv5 的

收稿日期: 2024-10-11 修订日期: 2025-01-20

基金项目: 农业农村部农业农村信息化宣传推广项目 (A150101); 国家自然科学基金项目 (52309050); 中国科技期刊卓越行动计划二期-《农业工程学报》中文领军期刊项目 (卓越二期-B1-036); 河南科技大学青年骨干教师项目 (4004-13450010); 河南省重点研发与推广专项 (科技攻关) 项目 (232102110264, 222102110452); 中国科学技术协会农村专业技术服务中心资助类项目 (20230508ZZ06210034); 河南省高等学校重点科研项目 (24B416001)

作者简介: 师翊, 博士, 在站博士后, 讲师, 研究方向为农业信息化、人工智能。Email: shiyigongteng@163.com

※通信作者: 王应宽, 博士, 研究员, 研究方向为农业机械化及信息化、智慧农业和数字出版。Email: wangyk@tcsae.org

高效梨果检测方法 YOLO-P, 通过优化网络结构, 提升了复杂果园环境中梨果的检测效率和准确性。

目前, 针对青杏果实的自动识别技术研究相对较少, 为了提高青杏识别的准确性并加快检测速度, 满足自动化农业生成的需求, 本研究基于 YOLOv8 模型框架, 将 CBAM (convolutional block attention module) 结构融入到 MobileNetV3 结构中, 并引入 BiFPN (bi-directional feature pyramid network) 和 PConv (partial convolution) 结构, 构建 MCBPnet 模型, 旨在实现对青杏果实的高效、精确检测, 推动青杏产业向现代化、智能化方向发展, 提高农业生产效率, 提升经济效益。

1 材料与方法

1.1 数据集构建

为了实现对青杏果实的精准识别, 本研究采取了一套细致的数据集构建流程。使用 iQOO 12 Pro 智能手机作为采集工具, 其后置主摄像头配备了 5 000 万像素的传感器和光圈值为 1.75 高进光量镜头, 能够捕捉到清晰度和多样化的图像。选取不同时间段进行拍摄, 以确保在不同的自然光照条件下收集图像, 从而增加数据集的多样性。本研究拍摄得到的原始青杏图像共有 510 张。在图像采集之后, 对图像进行了预处理, 包括裁剪、调整尺寸至 640×640 像素以及归一化处理以将像素值标准化到 0~1 的范围内。在图像标注阶段, 使用 Labellmg 工具对图像中的青杏果实进行了精确标注, 确保了数据标注的一致性和准确性。为了进一步丰富和增强数据集, 本文应用了数据增强技术, 主要包括旋转、缩放、翻转和添加噪声, 有助于提高数据集的复杂性, 并提升模型对环境变化的适应能力。最终构建了一个包含 1 020 张图像的数据集, 并将其按照 8:1:1 的比例精确地划分为训练集、验证集和测试集。图 1 展示了部分图像样本。



图 1 部分图像样本

Fig.1 Partial image samples

1.2 YOLOv8 目标检测模型

YOLOv8 模型沿用了 YOLO 系列的核心思想, 利用端到端的神经网络架构进行目标识别, 实现了较高的精度和推理效率^[26]。在主干网络的设计上, YOLOv8 利用较深的网络层次提升了特征提取的精度, 并采用轻量级

结构降低了模型的计算复杂度, 使得 YOLOv8 能够在保证精度的同时, 提高实时性能^[27]。YOLOv8 的颈部网络融合了 FPN (feature pyramid network) 和 PANet (path aggregation network) 结构。该设计使得 YOLOv8 能够在不同尺度上更有效地整合特征信息, 从而在目标检测任务中取得更好的性能表现^[28-29]。在头部网络上, YOLOv8 采用了 Anchor-Free 策略, 不依赖于预定义的锚框, 而是通过回归方式直接预测每个像素点对应的物体类别及其边界框。这种设计简化了模型的训练过程, 并提高了目标检测的灵活性^[30]。

1.3 MCBPnet 模型结构

为提高 YOLOv8 模型在面对光照变化、遮挡等复杂场景时的检测精度和鲁棒性, 并实现进一步的轻量化, 本研究对 YOLOv8 的主干网络、颈部网络和头部网络进行了优化和改进, 旨在资源受限环境下, 实现对复杂场景中青杏的高效识别。

1.3.1 主干网络模块

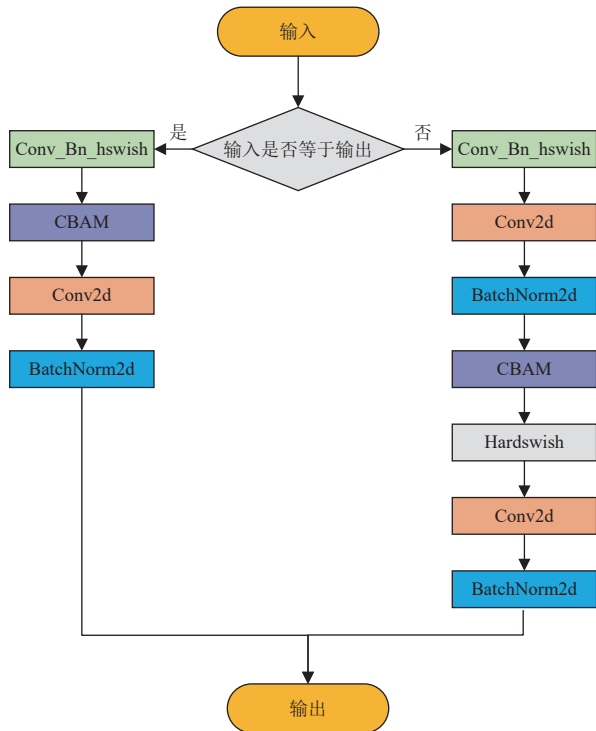
MobileNetV3 是一种为移动和嵌入式设备设计的轻量级深度学习模型, 它通过倒置残差块结构, 结合深度可分离卷积技术, 大幅减少了模型的计算负担^[31-33]。每个倒置残差块由扩展层、深度可分离卷积层和投影层组成。扩展层首先对输入特征图进行扩展, 增加通道数; 深度可分离卷积层使用深度卷积和逐点卷积提取特征; 投影层通过 1×1 的卷积减少通道数, 实现特征图的降维。此外, MobileNetV3 还引入了 SE (squeeze-and-excitation) 网络模块, 增强了模型对重要特征的捕捉能力。

CBAM 是一种有效的注意力机制, 融合通道和空间注意力模块增强对重要特征的关注^[34-36]。通道注意力模块通过全局平均池化获取通道的注意力权重, 而空间注意力模块则通过全局最大池化获取空间的注意力权重^[37-38]。这两个模块的注意力权重与原始特征图相乘, 用来增强重要特征并抑制不重要特征。

在 MobileNetV3 结构中, 采用 CBAM 机制代替倒置残差块中的 SE 模块, 构建了 IRCBAM (inverted residual convolutional block attention module) 模块。在扩展层之后, 应用 CBAM 的通道注意力和空间注意力模块, 然后通过深度可分离卷积层进行特征提取。在投影层之前, 将注意力权重与特征图相乘, 以增强模型对关键信息的捕捉能力。这种集成不仅可以提高模型的性能, 而且可保持 MobileNetV3 的轻量级特性, 使其适用于移动和嵌入式设备。IRCBAM 模块结构如图 2 所示。


1.3.2 颈部网络模块

在颈部网络中, 本研究采用了 BiFPN 结构作为颈部网络的关键组件, BiFPN 网络的结构如图 3 所示。BiFPN 是在 FPN 和 PANet 的基础上进行了深度优化的网络结构。FPN 通过搭建自顶向下的信息流通道, 将富含语义信息的高层特征图与富含细节信息的低层特征图相融合。而 PANet 则在 FPN 的基础上进行了改进, 不仅保留了 FPN 的自顶向下的融合路径, 而且增加了自底向上的融合路径, 形成了双向的特征融合结构^[39]。



注: Conv2 d 为二维卷积操作, BatchNorm2 d 为二维批量归一化操作, Hardswish 为激活函数, Conv_Bn_hswish 为一种集成 Conv2 d、BatchNorm2 d 和 Hardswish 的模块化结构, CBAM 为卷积块注意力模块。
Note: Conv2 d refers to the 2D convolution operation, BatchNorm2 d denotes the 2D batch normalization operation, Hardswish is an activation function, Conv_Bn_hswish is a modular structure that integrates Conv2 d, BatchNorm2 d, and Hardswish. CBAM stands for convolutional block attention module.

图2 IRCBAM 网络结构
Fig.2 The network structure of IRCBAM



注: FPN 为特征金字塔网络, PANet 为路径聚合网络, P3~P5 为不同层次的特征图。
Note: FPN refers to the feature pyramid network, PANet stands for path aggregation network, and P3 to P5 represent feature maps at different hierarchical levels.

图3 BiFPN 网络结构
Fig.3 The network structure of BiFPN


在 FPN 和 PANet 的基础上, BiFPN 通过构建自顶向下和自底向上的双向信息流通道, 实现了特征图之间深层次的信息交流和融合, 这对于精确识别青杏这类具有复杂背景和多变光照条件的目标尤为重要。BiFPN 的核心优势在于其能够动态调整不同尺度特征之间的权重, 使得模型能够更加关注于对当前任务至关重要的特征。这种加权特征融合技术不仅增强了模型对青杏的识别能力, 而且提高了特征的重用性, 优化了上采样和下采样过程中的信息传递效率。具体而言, BiFPN 通过自底向上的路径, 将低层次的高分辨率特征与高层次的低分辨率特征进行有效结合, 从而为青杏识别提供了更为丰富

的上下文信息。同时, 自顶向下的路径则允许模型从全局视角对特征进行优化, 进一步提升了检测的准确性。

1.3.3 头部网络模块

本研究采用 PConv 作为头部网络的核心模块, 旨在解决传统卷积操作在处理不完整数据时的局限性。该模块通过引入额外的掩码信息来适应这些不完整的数据, 从而提高模型的鲁棒性和准确性。PConv 模块接收两个输入: 特征图和相应的掩码图。其中掩码图用于指示特征图中哪些像素是有效的, 哪些是被遮挡或缺失的。在卷积操作中, 只有掩码图中标记为有效的像素才会参与到计算中。该模块首先对输入的特征图和掩码图进行卷积操作, 然后根据掩码图对卷积结果进行调整, 以确保被标记为无效的像素不会对最终的输出产生影响。最后, 根据调整后的卷积结果生成输出特征图, 该特征图可以直接用于后续的网络层或作为目标检测模型的最终输出。在实现 PConv 模块时, 选择了大小为 3×3 的卷积核, 使用了 ReLU 激活函数来引入非线性, 并采用了参数共享策略以减少模型的参数量。在目标检测任务中, 该模块提高了模型对不完整目标的识别能力, 与传统卷积相比, PConv 在处理遮挡和裁剪目标时, 能够获得更高的准确率和鲁棒性。

改进后的 PConv_Detect (partial convolution detect) 结构包含两个主要分支, 分别是回归分支和分类分支, 如图 4 所示。回归分支利用 PConv 模块对输入特征图的部分通道进行卷积运算, 以预测目标框的位置。这种设计减少了计算量, 同时保持了对目标位置的准确预测。分类分支同样采用 PConv 模块, 对目标的类别进行预测。通过减少计算冗余, PConv 有助于加速类别预测过程, 同时保持分类的准确性。此外, PConv 的设计还有助于减少模型的参数量和计算复杂度, 这对于在资源受限的设备上部署模型尤为重要。通过这种改进, MCBPnet 模型能够在保持高检测精度的同时, 提高模型的运行速度和效率。



注: Partial-Conv 为部分卷积操作, Conv 为卷积操作, Bbox.Loss 为边界框回归损失函数, Cls.Loss 为分类损失函数。
Note: Partial-Conv refers to the partial convolution operation, Conv denotes the convolution operation, Bbox.Loss is the bounding box regression loss function, and Cls.Loss is the classification loss function.

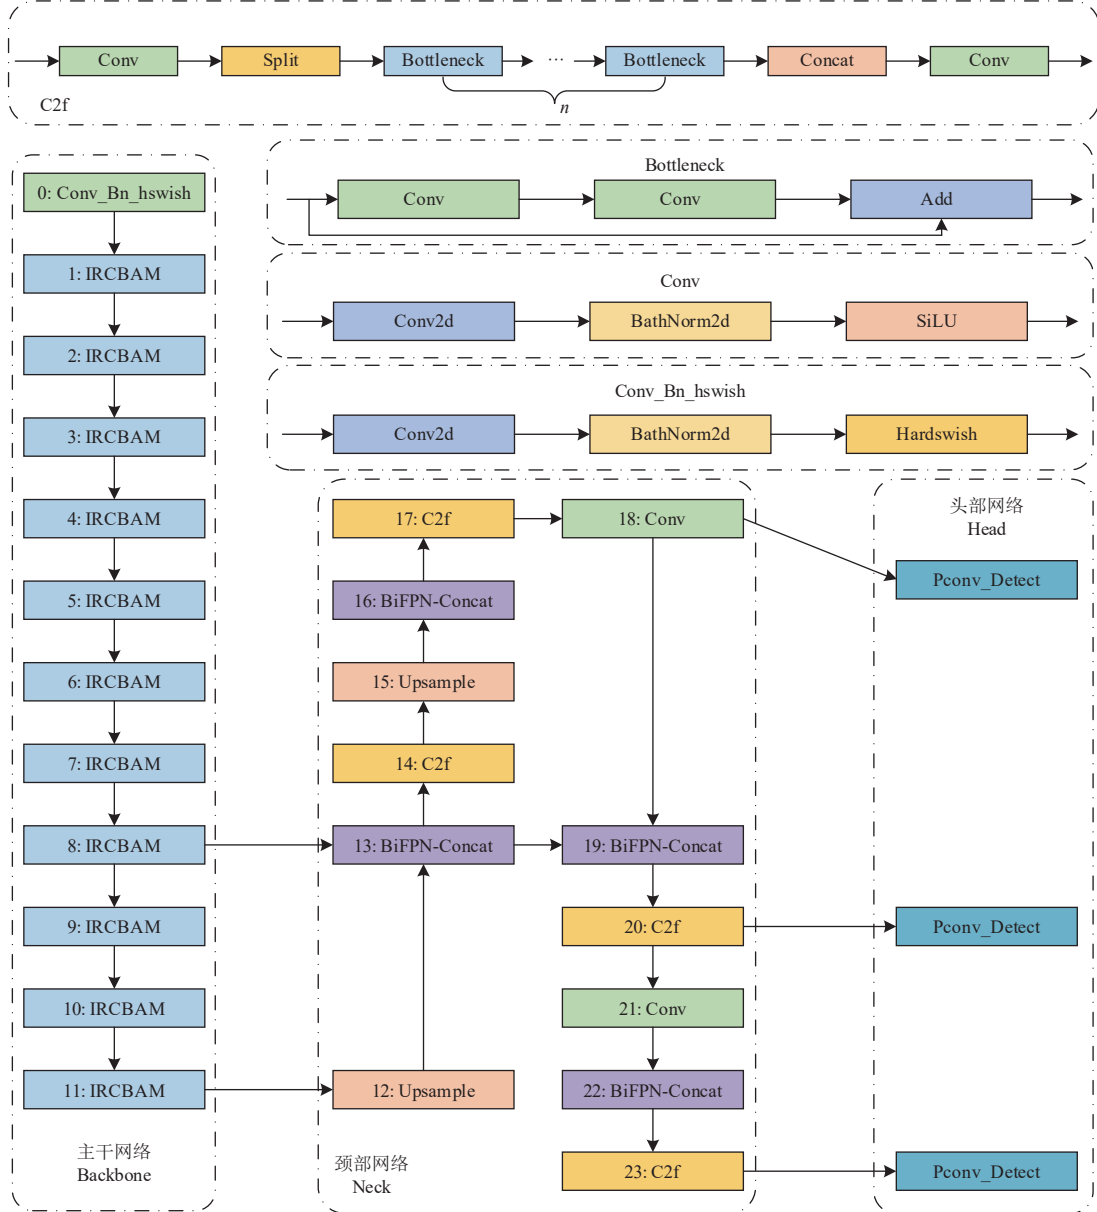
图4 PConv_Detect 结构
Fig.4 Structure of PConv_Detect

1.3.4 MCBPnet 网络构建

为实现对青杏的高效识别与检测, 本研究通过改进 YOLOv8 模型, 基于 MobileNetV3、CBAM、BiFPN 以及 PConv 结构, 构建了 MCBPnet 青杏识别模型, 其结构如图 5 所示。该模型基于 MobileNetV3 结构, 利用 CBAM 结构代替倒置残差块中的 SE 网络模块, 构建 IRCBAM 模块, 可增强特征提取能力, 同时保持模型的

轻量化特性。IRCBAM 模块在 MobileNetV3 的倒置残差块中集成了通道和空间注意力机制,以突出关键信息并抑制不重要特征。此外,MCBPnet 在颈部网络引入了 BiFPN 结构,通过构建自顶向下和自底向上的信息流通道,可实现特征图之间的深层次信息交流和融合,优化特征的重用性和信息传递效率。MCBPnet 模型在检测头

部分采用 PConv 结构,以适应不完整数据并提高模型的鲁棒性。PConv 结构通过引入掩码信息,仅让有效像素参与计算,从而在处理遮挡和裁剪目标时提高了识别的准确性。MCBPnet 的检测头结构包含回归分支和分类分支,均采用 PConv 模块以减少计算冗余,加速预测过程,并在资源受限的设备上实现模型的快速部署。



注: IRCBAM 为倒置残差卷积块注意力机制, Upsample 为上采样模块, Concat 为特征连接操作, BiFPN-Concat 是结合双向特征金字塔网络和特征连接操作的模块, PConv_Detect 为部分卷积检测头, SiLU 为激活函数, Add 为求和操作, n 为瓶颈层数量。

Note: IRCBAM refers to the inverted residual convolutional block attention module, Upsample denotes the upsampling module, and Concat represents the feature concatenation operation. BiFPN-Concat is a module that combines the bidirectional feature pyramid network and the feature concatenation operation. PConv_Detect stands for partial convolution detection head, SiLU is the activation function, Add refers to the summation operation, n is the number of bottleneck layer.

图5 MCBPnet 网络结构

Fig.5 Network structure of MCBPnet

1.4 评价指标

在本研究中,采用以下4个指标评价青杏识别任务中不同模型的性能:精确度(P)、召回率(R)、平均精度(mean average precision, mAP_{50})以及扩展平均精度(mAP_{50-95})。 mAP_{50} 是指在交并比(intersection over union, IoU)阈值为50%时,模型的平均精度均值,这

一指标用于评估模型在处理不同类别时的整体性能,通过计算各类别的平均精度(average precision, AP)并求其平均值得到,有助于了解模型的整体识别效果。而 mAP_{50-95} 则提供了一个更为细致的性能评估,其考虑了从50%到95%的不同IoU阈值,从而更全面地反映了模型对多样性条件的适应能力。各指标具体计算式如下:

$$P = \frac{TP}{TP + FP} \quad (1)$$

$$R = \frac{TP}{TP + FN} \quad (2)$$

$$mAP_{50} = \frac{1}{n} \sum_{i=1}^n AP_i \quad (3)$$

$$mAP_{50-95} = \frac{1}{m} \sum_{i=1}^m \frac{1}{10} \sum_{j=1}^{10} AP_{i,j} \quad (4)$$

式中 TP 表示真正例的样本数量, FP 表示假正例的样本数量, FN 表示假负例的样本数量。 n 为 IoU 阈值为 0.5 时的样本数量, m 为 IoU 阈值为 0.5~0.95 时的样本数量, AP_i 表示类别 i 在 IoU 阈值为 0.5 时的平均精度, $AP_{i,j}$ 表示类别 i 在 IoU 阈值为 $0.5+0.05 \times (j-1)$ 时的平均精度, j 为调节系数, $j \in [1, 10]$ 。

2 结果与分析

2.1 试验环境

本文试验使用的操作系统是 Ubuntu20.04, 使用 2.0.1 版本的 PyTorch 深度学习开发框架, CUDA 版本为 11.8, 3.10 版本的 Python 作为开发语言。试验中使用的中央处理器是 Intel(R) Xeon(R) CPU E5-2680 v4 @ 2.40 GHz。本试验中使用的 GPU 是 NVIDIA RTX A2000, 内存为 12 GB。在参数设置方面, 本研究采用了 YOLO 算法的原始参数配置, 学习率初始值为 0.01, 最终学习率也为 0.01, 保证了训练过程中学习率的稳定。批量大小设定为 16, 迭代次数为 300。其他参数如动量为 0.937, 权重衰减为 0.0005, 预热周期为 3, 预热初始动量为 0.8, 预热初始偏置学习率为 0.1。这些参数设置相互配合, 使模型能够在训练过程中快速收敛、稳定更新, 并具有良好的泛化能力, 从而在青杏识别任务中取得较好的性能表现。

2.2 MCBPnet 检测结果分析

本研究基于 MobileNetV3、CBAM、BiFPN 以及 PConv 结构, 构建了 MCBPnet 青杏识别模型。使用 MCBPnet 模型对数据集进行检测试验, 结果显示, MCBPnet 模型在青杏检测任务中的表现较为出色, 模型检测结果的 P 达到了 0.988, 能够以较高精度识别出青杏, 而召回率也达到了 0.985, 说明模型在识别过程中极少漏检, 确保了检测的全面性。此外, 模型的 mAP_{50} 达到了 0.994, 识别精度高, 而 IoU 阈值在 0.5~0.95 范围内, 平均精度依然保持在 0.968, 表明 MCBPnet 在青杏检测任务中具有较高的准确性和可靠性, 能够为相关应用提供技术支持。

图 6 显示了 MCBPnet 模型的精度变化, 通过在不同训练轮次中对模型性能的系统评估, 可以观察到模型的 P 、 R 、 mAP_{50} 和 mAP_{50-95} 呈现出较快的增长趋势。从图 6 可以看出, 从初始轮次的较低性能, 到训练结束时具有较高的精度提升, 随着训练的深入, 模型的预测能力和稳定性得到了增强。值得注意的是, 在训练的早期阶段,

模型的 R 相对较高, 表明其能够从数据集中召回更多的正样本, 但 P 较低, 说明其中包含了较多的假阳性。随着训练的进行, P 迅速提升, 表明模型在减少误判的同时保持了较高的 R , 反映了模型区分正负样本的能力得到了明显提高。特别是 mAP_{50-95} 值的持续增长, 表明模型在处理不同遮挡程度和尺度变化的青杏检测时, 表现出了良好的性能。上述结果表明, MCBPnet 模型随着训练的进行, 其识别青杏的能力逐渐增强, 最后达到了一个较高的精度水平, 证明了该模型在实际应用中的潜力和有效性。

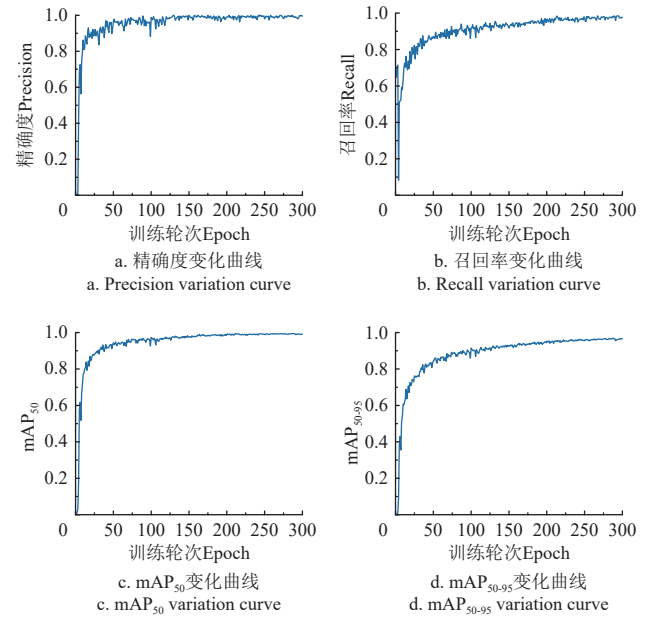


图 6 MCBPnet 模型精度变化曲线

Fig.6 Model accuracy variation curve of MCBPnet

模型检测结果的精确度、召回率与置信度之间的关系可进一步展示模型的性能, 具体如图 7 所示。




图 7 精确度、召回率与置信度关系曲线

Fig.7 Precision, recall and confidence curve

在精确度-置信度曲线中模型的识别精度在较低置信度 (0.1~0.2) 时快速上升, 并在接近 0.4 置信度时达到接近 1.0 的精度水平, 说明模型在置信度较低时即具有较好的分类能力, 整条曲线几乎平滑贴近 1.0, 在置信度 0.793 处达到了 1.0 的精度, 表明模型对青杏有较高的识别率。在召回率-置信度曲线中, 随着置信度增加, 召回率保持在较高水平, 当置信度接近 1.0 时召回率开始下降, 表明模型在高置信度下较为保守, 可能会漏掉一

些较难分类的青杏实例。综合精度和召回率的表现, 模型对青杏有着较为优秀的识别能力。

2.3 消融试验

本研究在 YOLOv8 的基础上进行了消融试验, 具体的精度结果如表 1 所示。根据表 1 数据, 原 YOLOv8 模型检测结果中, P 为 0.981, R 为 0.976, mAP_{50} 为 0.992, mAP_{50-95} 为 0.955, 参数量为 3.005 M, FLOPs 为 8.1 G。当以 MobilenetV3 作为主干网络架构时, 本研究以 CBAM 模块替代 SE 机制, 构建了 IRCBAM 结构, 模型的参数量和 FLOPs 有较大幅度下降, 相较于基线模型分别降低了 10.383% 和 27.160%, 展现出较为出色的轻量化效果。在引入 BiFPN 结构后, 模型的 P 提升至 0.992,

这表明 BiFPN 结构能够较为有效地提升模型的特征融合能力, 从而提高检测精度。引入 PConv_Detect 后, 模型的 R 、 mAP_{50} 和 mAP_{50-95} 分别提升至 0.986、0.994 和 0.970, 显示出 PConv_Detect 结构在增强模型精度方面的重要作用。

当 IRCBAM 和 BiFPN 或 PConv_Detect 组合引入时, 相较于单独引入 IRCBAM, 模型的精度有一定程度的提升, 但运算量也随之增加。最终的 MCBPnet 模型融合了以上 3 种模块, 其 mAP_{50} 和 mAP_{50-95} 分别达到 0.994 和 0.968, 参数量为 2.924 M, FLOPs 为 6.1G, 相较于基线模型, FLOPs 减少 24.69%, 表明 MCBPnet 模型在保持较高检测性能的同时, 能够有效减少运算量。

表 1 基于 YOLOv8 模型的消融试验

Table 1 Ablation experiments based on YOLOv8 model

MobilenetV3	IRCBAM	BiFPN	PConv_Detect	精确度 Precision	召回率 Recall	mAP_{50}	mAP_{50-95}	参数量 Parameters/M	运算量 FLOPs/G
—	—	—	—	0.981	0.976	0.992	0.955	3.005	8.1
—	√	—	—	0.958	0.959	0.982	0.928	2.693	5.9
—	—	√	—	0.992	0.971	0.990	0.954	3.005	8.1
—	—	—	√	0.981	0.986	0.994	0.970	3.140	8.1
—	√	√	—	0.996	0.946	0.987	0.954	2.693	5.9
—	√	—	√	0.959	0.974	0.987	0.954	2.828	5.9
—	—	√	√	0.998	0.985	0.995	0.974	3.140	8.1
—	√	√	√	0.988	0.985	0.994	0.968	2.924	6.1

注: “—” 表示不使用此模块, “√” 表示使用此模块, FLOPs 代表每秒浮点运算次数。

Note: “—” indicates not using this module, “√” indicates using this module, FLOPs represent floating point operations per second.

综上所述, 消融试验结果有效证明了 IRCBAM、BiFPN 和 PConv_Detect 模块在提升 YOLOv8 模型精确度或降低运算量方面的有效性。最终的 MCBPnet 模型在精度和计算效率之间取得了良好的平衡。

2.4 不同模型性能对比

为了证明 MCBPnet 模型的性能, 在对果园中青杏目标检测网络进行的试验中, 对比了多个模型的性能, 检测结果如表 2 所示。对比试验选取目前单阶段目标检测

的主流模型: RetinaNet 模型, EfficientDet 模型和 YOLO 系列模型。RetinaNet 模型虽然在 P 上达到了 0.998, 但其在 mAP_{50-95} 指标上较低, 为 0.907, FLOPs 为 6.9 G, 比 MCBPnet 模型高出 11.59%, 表明 RetinaNet 模型在计算资源消耗上较高。EfficientDet 在各项指标上表现较为均衡, mAP_{50} 和 mAP_{50-95} 分别为 0.991 和 0.945, 但检测速度较低, 为 65.789 帧/s, 检测速度比 MCBPnet 模型低 40.13%。

表 2 青杏识别模型检测结果精度

Table 2 Detection accuracy of green apricot recognition model

模型 Model	精确度 Precision	召回率 Recall	mAP_{50}	mAP_{50-95}	参数量 Parameters/M	运算量 FLOPs/G	检测速度 Detection speed/(帧·s ⁻¹)
RetinaNet	0.998	0.906	0.968	0.907	2.357	6.9	96.154
EfficientDet	0.993	0.951	0.991	0.945	3.852	5.1	65.789
YOLOv8n	0.981	0.976	0.992	0.955	3.005	8.1	64.516
YOLOv9 t	0.992	0.961	0.987	0.948	1.970	7.6	96.154
YOLOv10n	0.973	0.959	0.990	0.964	2.694	8.2	101.010
MCBPnet	0.988	0.985	0.994	0.968	2.924	6.1	109.890

YOLO 系列模型在本次试验中总体表现较好, YOLOv8n 在 mAP_{50} 和 mAP_{50-95} 上达到了 0.992 和 0.955, YOLOv9 t 和 YOLOv10n 在 mAP_{50-95} 上分别达到了 0.948 和 0.964, 显示了 YOLO 系列在目标检测上的优势, 但运算量也较高, YOLOv8n, YOLOv9 t 和 YOLOv10n 的 FLOPs 比 MCBPnet 模型分别高 32.79%, 24.59% 和 34.42%。MCBPnet 模型在所有模型中综合表现最佳, 其 mAP_{50} 和 mAP_{50-95} 分别为 0.994 和 0.968, 运算量为 6.1 G, 为 YOLOv8n 模型的 75.31%, 表明 MCBPnet 在保持高准确性的同时, 计算开销也较小。

在识别速度上, YOLOv9 t 和 YOLOv10n 的检测速度虽然接近 MCBPnet, 但运算量较高。RetinaNet 模型的 FLOPs 和检测速度两项指标均低于 MCBPnet,

EfficientDet 模型的 FLOPs 优于 MCBPnet, 为 5.1G, 比 MCBPnet 低 16.39%, 但检测速度低, 为 65.789 帧/s。MCBPnet 模型的检测速度最高, 达到 109.890 帧/s, 高于 YOLOv8n 模型的 64.516 帧/s, 检测速度提升 70.33%。

图 8 展示了在不同光照强度和遮盖条件下, 各模型检测效果的对比。在正常光照条件下, 各模型均展现出较好的检测效果, 但 EfficientDet 模型出现了误检情况。在较强光线条件下, 各模型识别结果的置信度较为接近, 仅有 YOLOv10n 存在误检的情况。当存在枝叶遮挡时, MCBPnet 模型能够较精准地识别目标, 并且具有较高的置信度, 而 YOLOv9 t、RetinaNet 和 EfficientDet 模型则出现了漏检或误检问题。在果实堆叠情况下, YOLOv9 t、RetinaNet 和 EfficientDet 模型也出现了误检或漏检情况。

整体来看, MCBPnet 模型能够提供较为准确的青杏识别结果, 并且置信度较高, 误检和漏检情况相对较少。




图8 不同条件下各模型检测效果对比

Fig.8 Comparison of detection performance of different models under various conditions

MCBPnet 模型在青杏识别任务上展现了较优的性能, 模型具有高准确率、高召回率以及较低的计算复杂度等特性, 不仅能够提高果园管理的效率, 还能够帮助果农准确地预测产量, 做出合理的种植决策, 推进果园自动化、智能化发展的进程。

3 讨论

MCBPnet 模型中的主干网络, 引入了 MobileNetV3 结构和 CBAM 结构, 构建了 IRCBAM 模块, 优化了模型的计算效率和参数利用率, 在保持较低计算成本的同时, 实现了较高的检测精度。BiFPN 作为一种特征金字塔网络, 通过双向信息流的设计, 增强了特征的融合和传递, 使得模型能够更好地捕捉青杏图像中的多尺度信息。此外, PConv 结构的引入为 MCBPnet 模型带来了处理不完整数据的能力。在目标检测领域, 尤其是在农业应用中, 图像往往存在遮挡或部分损坏的情况, PConv 通过学习遮挡区域的残差信息, 使得模型能够对这些不完整的数据进行有效的预测和识别。这种结构的引入提高了模型在处理遮挡和部分损坏青杏果实图像时的鲁棒性。

尽管 MCBPnet 模型在多个方面表现出色, 但在处理颜色有细微变化的果实或高密度果实簇时可能存在局限性。为了进一步提高 MCBPnet 模型的性能, 未来研究可以在优化特征融合、引入注意力机制、模型压缩和加速等方向进行改进, 进一步提升模型的性能, 从而更好地满足实际应用的需求。

4 结论

本文针对青杏果实的快速、高效检测提出 MCBPnet 目标识别模型, 该模型以 IRCBAM 为主干网络, 并引入了 BiFPN 结构和 PConv 结构, 有效提高了青杏的目标检测的精度和效率。主要结论如下:

1) MCBPnet 模型的参数量相对较少, 为 2.924M, 检测速度达到 109.890 帧/s, FLOPs 仅为 6.1 G, 实现了

模型的高效性和轻量化。

2) 在与 RetinaNet、EfficientDet、YOLO 系列模型等进行对比时, MCBPnet 在 mAP_{50} 、 mAP_{50-95} 等关键指标上显示出了较为明显的优势。MCBPnet 模型检测结果的 P 为 0.988, R 为 0.985, mAP_{50} 为 0.994, mAP_{50-95} 为 0.968, 表明模型在不同 IoU 阈值下都能保持较高的检测精度。

MCBPnet 模型在青杏的识别中展示出了较好的性能。通过结合 IRCBAM、BiFPN 和 PConv 技术, 不仅提高了模型的检测精度, 同时保持了模型的轻量化。未来的研究可以集中在提高模型的环境适应性和实时性能上, 以实现更广泛的应用。

【参考文献】

- [1] 李茂, 肖洋轶, 宗望远, 等. 基于改进 YOLOv8 模型的轻量化板栗果实识别方法[J]. 农业工程学报, 2024, 40(1): 201-209.
LI Mao, XIAO Yangyi, ZONG Wangyuan, et al. Detecting chestnuts using improved lightweight YOLOv8[J]. Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE), 2024, 40(1): 201-209. (in Chinese with English abstract)
- [2] 熊明明, 李晓娟. 基于图像与深度信息融合的西梅果实识别定位方法[J]. 中国农机化学报, 2024, 45(9): 172-177, 353.
XIONG Mingming, LI Xiaojuan. Recognition and positioning method of prune fruit based on fusion of image and depth information[J]. Journal of Chinese Agricultural Mechanization, 2024, 45(9): 172-177, 353. (in Chinese with English abstract)
- [3] 肖永丽, 张少华, 库完汗·吾甫尔, 等. 新疆巴音郭楞蒙古自治州特色林果业发展现状及对策[J]. 果树资源学报, 2024, 5(5): 118-122.
XIAO Yongli, ZHANG Shaohua, KUWANHAN Wufuer, et al. Development situations and countermeasures of characteristic forest and fruit industry in bayingol mongolian autonomous prefecture, Xinjiang[J]. Journal of Fruit Resources, 2024, 5(5): 118-122. (in Chinese with English abstract)
- [4] 葛晓军, 阿依波塔·阿那克塔西, 路柯怡. 新内生发展理论下新疆伊犁州树上干杏产业发展研究[J]. 北方园艺, 2024(16): 138-143.
GE Xiaojun, Ayipota-ANAKTAXI, LU Keyi. Study on the development of dried apricot industry on trees in Ili prefecture, Xinjiang under the new endogenous development theory[J]. Northern Horticulture, 2024(16): 138-143. (in Chinese with English abstract)
- [5] 李辉, 张俊, 俞烁辰, 等. 基于深度学习的类球状水果采摘识别算法研究进展[J]. 果树学报, 2025(1): 1-19.
LI Hui, ZHANG Jun, YU Shuochen, et al. Research progress of globular fruit picking recognition algorithm based on deep learning[J]. Journal of Fruit Science, 2025(1): 1-19. (in Chinese with English abstract)
- [6] 安晓东, 李阳, 刘柳, 等. 基于机器视觉的水果分拣算法综述[J]. 自动化技术与应用, 2025(1): 1-12.
AN Xiaodong, LI Yang, LIU Liu, et al. A review of fruit sorting based on machine vision[J]. Techniques of Automation and Applications, 2025(1): 1-12. (in Chinese with English abstract)
- [7] TULBURE A A, TULBURE A A, DULF E H. A review on modern defect detection models using DCNNs-Deep convolutional neural networks[J]. Journal of Advanced Research, 2022, 35: 33-48.
- [8] HE W, GAGE J L, RELLÁN-ÁLVAREZ R, et al. Swin-Roleaf: A new method for characterizing leaf azimuth angle in large-scale maize plants[J]. Computers and Electronics in Agriculture, 2024, 224: 109120.
- [9] 陈禹, 吴雪梅, 张珍, 等. 基于改进 YOLOv5s 的自然环境下茶

- 叶病害识别方法[J]. 农业工程学报, 2023, 39(24): 185-194. CHEN Yu, WU Xuemei, ZHANG Zhen, et al. Method for identifying tea diseases in natural environment using improved YOLOv5s[J]. Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE), 2023, 39(24): 185-194. (in Chinese with English abstract)
- [10] 耿端阳, 王其欢, 李华彪, 等. 基于深度学习的玉米籽粒破损在线检测技术[J]. 农业工程学报, 2023, 39(22): 270-278. GENG Duanyang, WANG Qihuan, LI Huabiao, et al. Online detection technology for broken corn kernels based on deep learning[J]. Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE), 2023, 39(22): 270-278. (in Chinese with English abstract)
- [11] 谭厚森, 马文宏, 田原, 等. 基于改进 YOLOv8n 的香梨目标检测方法[J]. 农业工程学报, 2024, 40(11): 178-185. TAN Housen, MA Wenhong, TIAN Yuan, et al. Improved YOLOv8n object detection of fragrant pears[J]. Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE), 2024, 40(11): 178-185. (in Chinese with English abstract)
- [12] 房俊龙, 胡宇航, 戴百生, 等. 采用改进 CenterNet 模型检测群养生猪目标[J]. 农业工程学报, 2021, 37(16): 136-144. FANG Junlong, HU Yuhang, DAI Baisheng, et al. Detection of group-housed pigs based on improved CenterNet model[J]. Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE), 2021, 37(16): 136-144. (in Chinese with English abstract)
- [13] 马超伟, 张浩, 马新明, 等. 基于改进 YOLOv8 的轻量化小麦病害检测方法[J]. 农业工程学报, 2024, 40(5): 187-195. MA Chaowei, ZHANG Hao, MA Xinming, et al. Method for the lightweight detection of wheat disease using improved YOLOv8[J]. Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE), 2024, 40(5): 187-195. (in Chinese with English abstract)
- [14] WEN C, WEN J, LI J, et al. Lightweight silkworm recognition based on Multi-scale feature fusion[J]. *Computers and Electronics in Agriculture*, 2022, 200: 107234.
- [15] 刘龙申, 舒翠霓, 李波, 等. 基于 EfficientDet 的围产期母猪姿态识别[J]. 农业机械学报, 2022, 53(4): 271-279. LIU Longshen, SHU Cuini, LI Bo, et al. Recognition of perinatal sows' posture based on EfficientDet algorithm[J]. Transactions of the Chinese Society for Agricultural Machinery, 2022, 53(4): 271-279. (in Chinese with English abstract)
- [16] 陈锋军, 张新伟, 朱学岩, 等. 基于改进 EfficientDet 的油橄榄果实成熟度检测[J]. 农业工程学报, 2022, 38(13): 158-166. CHEN Fengjun, ZHANG Xinwei, ZHU Xueyan, et al. Detection of the olive fruit maturity based on improved EfficientDet[J]. Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE), 2022, 38(13): 158-166. (in Chinese with English abstract)
- [17] 孙俊, 钱磊, 朱伟栋, 等. 基于改进 RetinaNet 的果园复杂环境下苹果检测[J]. 农业工程学报, 2022, 38(15): 314-322. SUN Jun, QIAN Lei, ZHU Weidong, et al. Apple detection in complex orchard environment based on improved RetinaNet[J]. Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE), 2022, 38(15): 314-322. (in Chinese with English abstract)
- [18] 姚青, 谷嘉乐, 吕军, 等. 改进 RetinaNet 的水稻冠层害虫为害自动检测模型[J]. 农业工程学报, 2020, 36(15): 182-188. YAO Qing, GU Jiale, LYU Jun, et al. Automatic detection model for pest damage symptoms on rice canopy based on improved RetinaNet[J]. Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE), 2020, 36(15): 182-188. (in Chinese with English abstract)
- [19] 刘双印, 范文婷, 邓皓, 等. 采用改进 RetinaNet 的笼养肉鸽繁育期个体检测模型[J]. 农业工程学报, 2022, 38(13): 184-193. LIU Shuangyin, FAN Wenting, DENG Hao, et al. Individual detection model for caged meat pigeons during breeding period based on improved RetinaNet[J]. Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE), 2022, 38(13): 184-193. (in Chinese with English abstract)
- [20] 黄家才, 赵雪迪, 高芳征, 等. 基于改进 YOLOv5s 的草莓多阶段识别检测轻量化算法[J]. 农业工程学报, 2023, 39(21): 181-187. HUANG Jiakai, ZHAO Xuedi, GAO Fangzheng, et al. Recognizing and detecting the strawberry at multi-stages using improved lightweight YOLOv5s[J]. Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE), 2023, 39(21): 181-187. (in Chinese with English abstract)
- [21] 王磊磊, 王斌, 李东晓, 等. 基于改进 YOLOv5 的菇房平菇目标检测与分类研究[J]. 农业工程学报, 2023, 39(17): 163-171. WANG Leilei, WANG Bin, LI Dongxiao, et al. Object detection and classification of pleurotus ostreatus using improved YOLOv5[J]. Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE), 2023, 39(17): 163-171. (in Chinese with English abstract)
- [22] 吴利刚, 陈乐, 刘泽鹏, 等. 基于 YOLOv8-ABW 的黄花成熟度检测方法[J]. 农业工程学报, 2024, 40(13): 262-272. WU Ligang, CHEN Le, LIU Zepeng, et al. YOLOv8-ABW based method for detecting *Hemerocallis citrina* Baroni maturity[J]. Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE), 2024, 40(13): 262-272. (in Chinese with English abstract)
- [23] 张震, 周俊, 江自真, 等. 基于改进 YOLO v7 轻量化模型的自然果园环境下苹果识别方法[J]. 农业机械学报, 2024, 55(3): 231-242, 262. ZHANG Zhen, ZHOU Jun, JIANG Zizhen, et al. Lightweight apple recognition method in natural orchard environment based on improved YOLO v7 model[J]. Transactions of the Chinese Society for Agricultural Machinery, 2024, 55(3): 231-242, 262. (in Chinese with English abstract)
- [24] 刘莫尘, 褚镇源, 崔明诗, 等. 基于改进 YOLO v8-Pose 的红熟期草莓识别和果柄检测[J]. 农业机械学报, 2023, 54(S2): 244-251. LIU Mochen, CHU Zhenyuan, CUI Mingshi, et al. Red ripe strawberry recognition and stem detection based on improved YOLO v8-Pose[J]. Transactions of the Chinese Society for Agricultural Machinery, 2023, 54(S2): 244-251. (in Chinese with English abstract)
- [25] SUN H, WANG B, XUE J. YOLO-P: An efficient method for pear fast detection in complex orchard picking environment[J]. *Frontiers in Plant Science*, 2023(13): 1089454.
- [26] 张荣华, 白雪, 樊江川. 复杂场景下害虫目标检测算法: YOLOv8-Extend[J]. 智慧农业(中英文), 2024, 6(2): 49-61. ZHANG Ronghua, BAI Xue, FAN Jiangchuan. Crop pest target detection algorithm in complex scenes: YOLOv8-Extend[J]. *Smart Agriculture*, 2024, 6(2): 49-61. (in Chinese with English abstract)
- [27] SUN D, ZHANG K, ZHONG H, et al. Efficient tobacco pest detection in complex environments using an enhanced YOLOv8 model[J]. *Agriculture*, 2024, 14(3): 14030353.
- [28] HUANG L, CHEN J, LI H, et al. Excellent tomato detector based on pruning and distillation to balance accuracy and lightweight[J]. *Computers and Electronics in Agriculture*, 2024, 227: 109520.
- [29] YE R, SHAO G, HE Y, et al. YOLOv8-RMDA: Lightweight YOLOv8 network for early detection of small target diseases in tea[J]. *Sensors*, 2024, 24(9): 2896.
- [30] GU Z, HE D, HUANG J, et al. Simultaneous detection of fruits and fruiting stems in mango using improved YOLOv8 model deployed by edge device[J]. *Computers and Electronics in Agriculture*, 2024, 227: 109512.
- [31] 孙俊, 吴兆祺, 贾忆琳, 等. 基于改进 YOLOv5s 的果园环境葡萄检测[J]. 农业工程学报, 2023, 39(18): 192-200.

- SUN Jun, WU Zhaoqi, JIA Yilin, et al. Detecting grape in an orchard using improved YOLOv5s[J]. Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE), 2023, 39(18): 192-200. (in Chinese with English abstract)
- [32] ZHAO L, WANG L. A new lightweight network based on MobileNetV3[J]. KSII Transactions on Internet and Information Systems (TIIS), 2022, 16(1): 1-15.
- [33] SI H, WANG Y, ZHAO W, et al. Apple surface defect detection method based on weight comparison transfer learning with MobileNetV3[J]. *Agriculture*, 2023, 13(4): 13040824.
- [34] WOO S, PARK J, LEE J Y, et al. Cbam: Convolutional block attention module[C]// Proceedings of the European conference on computer vision (ECCV). Munich, Germany: Springer, 2018: 3-19.
- [35] YU X, GUO H, YUAN Y, et al. An improved medical image segmentation framework with Channel-Height-Width-Spatial attention module[J]. *Engineering Applications of Artificial Intelligence*, 2024, 136: 108751.
- [36] 田有文, 覃上声, 闫玉博, 等. 基于改进 YOLOv8 的田间复杂环境下蓝莓成熟度检测[J]. 农业工程学报, 2024, 40(16): 153-162.
- TIAN Youwen, QIN Shangsheng, YAN Yubo, et al. Detecting blueberry maturity under complex field conditions using improved YOLOv8[J]. Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE), 2024, 40(16): 153-162. (in Chinese with English abstract)
- [37] 郑俊键, 兰玉彬, 熊万杰, 等. 基于 YOLOv5s 改进模型的小白菜虫害识别方法[J]. 农业工程学报, 2024, 40(13): 124-133.
- ZHENG Junjian, LAN Yubin, XIONG Wanjie, et al. Method for identification of Pak choi pests and diseases based on improved YOLOv5s[J]. Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE), 2024, 40(13): 124-133. (in Chinese with English abstract)
- [38] 陈慧颖, 宋青峰, 常天根, 等. 基于 YOLOv5m 和 CBAM-CPN 的单分蘖水稻表型参数提取[J]. 农业工程学报, 2024, 40(2): 307-314.
- CHEN Huiying, SONG Qingfeng, CHANG Tiangen, et al. Extraction of the single-tiller rice phenotypic parameters based on YOLOv5m and CBAM-CPN[J]. Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE), 2024, 40(2): 307-314. (in Chinese with English abstract)
- [39] 方国文, 何超, 王鑫泽. 基于 YOLOv8n 的轻量级巴旦木果实识别方法[J]. 江苏农业学报, 2024, 40(9): 1662-1670.
- FANG Guowen, HE Chao, WANG Xinze. Lightweight almond fruit recognition method based on YOLOv8n[J]. Jiangsu Journal of Agricultural Sciences, 2024, 40(9): 1662-1670. (in Chinese with English abstract)

MCBPnet as an efficient and lightweight recognition model for green apricot fruits

SHI Yi^{1,2,3}, WANG Yingkuan^{1,3*}, WANG Fei², QING Shunhao², ZHAO Long⁴, YUWEN Xingcan²

(1. Academy of Agricultural Planning and Engineering, Ministry of Agriculture and Rural Affairs, Beijing 100125, China; 2. College of Agricultural Equipment Engineering, Henan University of Science and Technology, Luoyang 471003, China; 3. Chinese Society of Agricultural Engineering, Beijing 100125, China; 4. College of Horticulture and Plant Protection, Henan University of Science and Technology, Luoyang 471003, China)

Abstract: Intelligent and automation technologies have been widely applied to agricultural production in recent years. A green apricot is one of the most significant economic fruits in Asian areas. However, traditional identification cannot fully meet large-scale production under complex environmental conditions in precision management. Fruit recognition and detection technologies can be required to enhance the accuracy and efficiency of large-scale production at present. In this study, an efficient and lightweight target recognition model (MCBPnet) was developed to automatically detect the green apricot fruits using advanced deep learning. The CBAM (convolutional block attention module) was first integrated into the MobileNetV3 architecture. The precision of the model was significantly enhanced to identify the apricot fruits with the most rich image areas. The regions of an image were then prioritized with the most relevant to fruit detection. More computational resources were effectively allocated to the features closely associated with the task. As a result, the model structure, IRCBAM (inverted residual convolutional block attention module) was then developed to incorporate as the backbone network of MCBPnet. BiFPN (Bi-directional feature pyramid network) was also introduced into the neck network, in order to further enhance the performance of the model. A feature pyramid was constructed to capture the multi-scale features from images using the BiFPN model. The fruits with varying sizes were then detected within a single frame. A high detection rate was also maintained in a wide range of fruit sizes and orientations. Moreover, some occlusions were also removed during detection, where the fruits were partially obscured by leaves or other fruits. The PConv (partial convolution) structure was utilized in the detection head. The high accuracy of detection was achieved, even when only a portion of a fruit was visible. As such, reliable recognition was obtained to increase its accuracy and robustness under conditions of partial visibility. The results demonstrated that the MCBPnet model achieved significant advantages across key performance metrics, including precision and mAP₅₀. Specifically, the high accuracy of detection was obtained with a precision of 0.988, an mAP₅₀ of 0.994. Furthermore, the detection speed of the MCBPnet model was 109.890 frames/s, which was 70.33% higher than that of the YOLOv8n model, and the model arithmetic was 6.1 G, which was 75.31% of that of the original one. This lightweight model was also deployed on edge devices, such as drones or handheld scanners, without any energy-intensive computational resources. In summary, the high-performance metrics were achieved by the MCBPnet model. The effectiveness of the integrated techniques was validated to maintain high accuracy during agricultural automation. Various indicators represented the significant advancement in the MCBPnet model. Advanced deep learning techniques and lightweight can be expected to improve the efficiency and accuracy of apricot detection during harvesting. The findings can provide technological support to the automated recognition and picking of green apricots. This MCBPnet model can greatly contribute to modern, intelligent, and sustainable crop management, thus driving the transition toward more efficient and intelligent agricultural practices.

Keywords: recognition; object detection; computer vision; lightweight model; green apricot fruits; automated agriculture